

1

1과목 : 빅데이터 분석 기획

- 1 과목(빅데이터 분석 기획) 주요 내용		
빅데이터의 이해	빅데이터 개요 및 활용	빅데이터의 특징
		빅데이터의 가치
		데이터 산업의 이해
	빅데이터 기술 및 제도	빅데이터 조직 및 인력
		빅데이터 플랫폼
		빅데이터와 인공지능
데이터분석 계획	분석방안 수립	개인정보 보호제도
		개인정보 활용
	분석 작업 계획	분석 로드맵 설정
		분석 문제 정의
데이터 수집 및 저장 계획	데이터 수집 및 전환	데이터 분석 방안
		데이터 확보 계획
		분석 절차 및 작업 계획
	데이터 적재 및 저장	데이터 수집
		데이터 유형 및 속성 파악
		데이터 변환

빅데이터의 이해

1. 빅데이터 개요 및 활용


-빅데이터의 특징

- **데이터의 정의**
 - 데이터: 있는 그대로의 객관적 사실, 가공되지 않은 상태 (주문수량)
 - **정보**: 데이터로부터 가공된 자료 (베스트셀러)
- **빅데이터 출현 배경**
 - 인터넷 확산, 스마트폰 보급, 클라우드 컴퓨팅으로 인한 **경제성 확보**, 저장매체 가격하락, 하둡을 활용한 **분산 컴퓨팅**, 비정형 데이터 확산
- **빅데이터 활용 위한 3대 요소 : '인자기' -** 축구선수 ㅋㅋ
 - **인력** / **자원(데이터)** / **기술**
- **★빅데이터의 3V (가트너 정의)**
 - (1) **Volume**(규모) : 데이터 양 증가
 - (2) **Variety**(다양성) : 데이터 유형 증가
 - (3) **Velocity**(속도) : 데이터 생성, 처리 속도 증가
 - (4) **그 외 5V에 포함되는 요소**

-Value(가치) : 숨겨진 가치 발견이 중요 -Veracity(신뢰성) : 고품질 데이터

다음중 빅데이터의 3V가 아닌 것은?

• ★DIKW 피라미드




- (1) 데이터(Data) : 있는 그대로의 사실 (A대리점 핸드폰 100만원, B대리점 핸드폰 200만원)
- (2) 정보(Information) : Data를 통해 **패턴** 인식 (A대리점이 핸드폰이 싸다)
- (3) 지식(Knowledge) : 패턴을 통해 **예측** (A에서 핸드폰을 사면 이득을 보겠다)
- (4) 지혜(Wisdom) : **창의적**인 산물 (A대리점의 다른 기기들도 B대리점보다 저렴 할 것이다)

• **암묵지, 형식지간 상호작용**

- **암묵지** : 개인에게 습득되고 겉으로 드러나지 않음
 - **형식지** : 문서, 매뉴얼 등의 형상화된 지식
 - 1) **공통화** : 암묵지 지식을 다른 사람에게 알려줌
 - 2) **표출화** : 암묵지 지식을 매뉴얼이나 문서로 전환
 - 3) **연결화** : 교재, 매뉴얼에 새로운 지식 추가
 - 4) **내면화** : 만들어진 교재, 매뉴얼에서 다른 사람의 암묵지를 터득
- '공표연내'

• **데이터베이스의 개념**



- (1) DB : 일정 구조에 맞게 조직화된 **데이터의 집합**
 - **스키마** : DB의 구조와 제약조건에 관한 전반적 명세 (외부스키마, 개념스키마, 내부스키마)
 - **인스턴스** : 데이터 개체를 구성하는 속성에 대한 데이터 타입과 값



- ★**메타데이터** : 데이터를 설명하는 데이터, 데이터 구조를 설명하고 검색하는데 활용
- **인덱스** : 정렬, 탐색을 위한 데이터의 이름

(2) DBMS : DB를 관리, 접근 환경 제공하는 소프트웨어

1) 관계형 DBMS : 테이블(표)로 정리



2) NoSQL DBMS : 비정형 데이터를 저장하고 처리 → 동영상, 인스타그램 등

(3) SQL : 데이터 베이스에 접근할 수 있는 하부언어

1) 정의언어(DDL) : CREATE, ALTER, DROP

2) 조작언어(DML) : SELECT, INSERT, DELETE, UPDATE

3) 제어언어(DCL) : COMMIT, ROLLBACK, GRANT, REVOKE

• ★데이터베이스의 특징

(1) 공용 데이터: 여러 사용자가 다른 목적으로 데이터 공동 이용

(2) 통합된 데이터: 동일한 데이터 중복되어 있지 않음

(3) 저장된 데이터: 저장매체에 저장

(4) 변화되는 데이터: 새로운 데이터 추가, 수정, 삭제에도 현재의 정확한 데이터 유지
→ '공통저번'

• 기업 활용 데이터베이스 (폴네임으로 외우기)

- OLTP(Online Transaction Processing) : 데이터를 수시로 갱신 (거래단위)
- OLAP(Online Analytical Processing) : 다차원 데이터를 대화식으로 분석
- CRM(Customer Relationship Management) : 고객과 관련 자료 분석, 마케팅 활용
- SCM(Supply Chain Management) : 공급망 연결 최적화
- ERP(Enterprise Resource Planning) : 기업 경영 자원을 효율화
- RTE(Real-Time Enterprise) : 최신 정보로 빠른 의사결정 지원
- BI(Business Intelligence) : 기업 보유 데이터 정리, 분석하는 리포트 중심 도구
- BA(Business Analytics) : 통계 기반 비즈니스 통찰력

- Block Chain : 네트워크에 참여한 모든 사용자가 정보를 분산, 저장
- KMS(Knowledge Management System) : 기업의 모든 지식을 포함

- 빅데이터의 가치

• 빅데이터 가치 산정이 어려운 이유

- (1) 특정 데이터를 언제, 어디서, 누가 활용할지 알 수 없음
- (2) 기존에 가치 없는 데이터도 새로운 분석기법으로 가치를 창출

• ★빅데이터가 만들어내는 변화

- (1) 표본조사(데이터 비쌈 표본을 뽑아 조사) → 전수조사
 - (2) 사전조사 → 사후처리
 - (3) 질 → 양
 - (4) 인과관계 → 상관관계
- '전후양상'

- 데이터 산업의 이해

• 데이터 산업의 발전

- 처리 → 통합 → 분석 → 연결 → 권리

- 1) 처리 : 프로그래밍 언어를 활용한 데이터의 처리
- 2) 통합 : DBMS의 등장
- 3) 분석 : 빅데이터 분석 기술의 발전
- 4) 연결 : API를 활용한 모듈들의 연결
- 5) 권리 : 마이데이터(MyData)를 활용한 데이터의 주권 행사


*마이데이터 : 자신의 신용 정보를 다른 제3자에게 제공하여 서비스를 제공받는 제공받는 제도 (금융 어플)

• 데이터 사이언스

- 데이터와 관련된 모든 분야의 전문지식을 종합한 학문
- 정형 / 비정형 데이터를 막론하고 데이터를 분석 (총체적 접근법)

• 데이터 사이언스 핵심 구성요소: 'AIBI'

- (1) Analytics : 이론적 지식
- (2) IT : 프로그래밍적 지식
- (3) 비즈니스 분석 : 비즈니스적 능력



• 데이터 사이언티스트의 필요역량

(1) **하드 스킬(Hard Skill)** : 이론적 지식(수학, 통계학, 가설검정 등), 가트너 제시 역량에 미포함

(2) **소프트 스킬(Hard Skill)** : 스토리텔링, 리더십, 창의력, 분석 등

→ 하드스킬은 이과적, 소프트 스킬은 문과적인 느낌

다음중 하드스킬이 아닌 것은? 소프트 스킬이 아닌것은? 스킬의 성격이 다른 것은?

• 하둡(Hadoop)

- 여러 컴퓨터를 하나로 묶어 대용량 데이터를 처리하는 오픈 소스 빅데이터 솔루션

(1) 하둡 코어프로젝트

1) ★HDFS : 분산 파일 시스템

2) MapReduce

- 분산된 데이터를 병렬로 처리

- 클라이언트, 잡 트래커, 태스크 트래커로 구성

▼ 참고

1. 클라이언트 (Client)

- 사용자가 **잡(Job)** 을 제출하는 주체
- 맵리듀스 프로그램(코드) + 입력 데이터 + 실행 설정을 **잡트래커에 전달**
- 결과가 완료되면 최종적으로 사용자에게 반환

2. 잡 트래커 (JobTracker)

- 마스터 노드에서 동작
- 클라이언트가 보낸 Job을 받아서 **작은 작업(Task)** 으로 나눔
- 클러스터 전체 상태(리소스, 실행 현황)를 모니터링
- **태스크 트래커(TaskTracker)에 작업을 분배하고 관리**
- 장애가 발생하면 다른 노드로 재할당

👉 쉽게 말해, “감독관(스케줄러)” 역할

3. 태스크 트래커 (TaskTracker)

- 워커 노드에서 동작
- 잡트래커가 내려준 작업(Map 또는 Reduce)을 실제로 실행
- 실행 상태(진행률, 오류 등)를 **잡트래커에 주기적으로 보고**
- 여러 Task 슬롯을 가지고 있어 병렬 처리 가능

👉 쉽게 말해, “일꾼(작업자)” 역할

- 패턴 종류 : 조인 패턴, 그룹화 패턴, 단어카운트 패턴, 통계 패턴, 필터링 패턴

▼ 참고

정리 표

패턴	설명	예시
조인 패턴	여러 데이터셋을 키 기준으로 합침	고객 + 주문 데이터
그룹화 패턴	같은 키 기준으로 데이터 묶음	상품별 매출 집계
단어 카운트 패턴	단어 빈도수 계산	텍스트 → {단어: 빈도}
통계 패턴	합계, 평균, 최대·최소 등 계산	학생 점수 통계

패턴	설명	예시
필터링 패턴	조건 맞는 데이터만 추출	로그 중 404 오류만 추출

(2) 하둡 에코시스템

- 다양한 서브 프로젝트들의 모임

1) 분산 코디네이터 : Zookeeper

2) 분산 리소스관리 : YARN, Mesos

3) 데이터 저장 : HBase, HDFS, Kudu

4) 데이터 수집 : Chukwa, Flume, Scribe, Kafka

5) 데이터 처리 : Pig, Mahout, Spark, Impale, Hive, MapReduce

• 데이터 단위 : '패지요!'

- B > KB < MB < GB < TB < PB < EB < ZB < YB (9) (Peta < Exa < Zetta < Yotta)

단위	데이터 양
바이트 (byte, B)	1 byte = 2 ⁰ B
킬로바이트 (Kilobyte, KB)	1024 B = 2 ¹⁰ B
메가바이트 (Megabyte, MB)	1024 KB = 2 ²⁰ B
기가바이트 (Gigabyte, GB)	1024 MB = 2 ³⁰ B
테라바이트 (Terabyte, TB)	1024 GB = 2 ⁴⁰ B
페타바이트 (Petabyte, PB)	1024 TB = 2 ⁵⁰ B
엑사바이트 (Exabyte, EB)	1024 PB = 2 ⁶⁰ B
제타바이트 (Zettabyte, ZB)	1024 EB = 2 ⁷⁰ B
요타바이트 (Yottabyte, YB)	1024 ZB = 2 ⁸⁰ B

▼ 블로그 참고

하드용량도 테라바이트(TB) 시대가 되어 킬로 메가 기가 테라까지는 익숙하다.

하지만 페타바이트 부터 요타바이트까지 순서가 헷갈린다. 페타 엑사 제타 요타를 데이터 용량 작은 것부터 순서로

PEZY (발음대로 페지~) 라고 외우면 쉬울 듯 하다. (ADsP에서도 크기 순서대로 묻는 문제가 출제 된다.)

[참고]

1. 요타바이트 보다 210 배 큰 크기의 단위는 브론토바이트 (Brontobyte, 1BB = 1024YB) 이다.

2. byte의 약자로는 MB, GB와 같이 B를 쓰고, b를 쓰면 bit가 되므로 1/8 크기가 되니 (1byte = 8bits) 유의해야한다.

• 빅데이터 가치 패러다임 변화

- Digitalization → Connection → Agency

(1) Digitalization : 아날로그 세상을 디지털화

(2) Connection : 디지털화된 정보들의 연결

(3) Agency : 연결을 효과적으로 관리

→ DigitalCA메라

- 빅데이터 가치 패러다임 변화

- Digitalization → Connection → Agency

(1) Digitalization : 아날로그 세상을 디지털화

(2) Connection : 디지털화된 정보들의 연결

(3) Agency : 연결을 효과적으로 관리

→ 'DigitalCa메라'

- 빅데이터 조직 및 인력

- ★조직 및 인력방안 수립(DSCoE: 분석조직)

- 집중 구조 : 독립적인 전담 조직 구성 (중복 업무 가능성 존재)
- 기능구조 : 해당 부서에서 직접 분석 (DSCoE가 없음)
- 분산 구조 : 분석 조직 인력을 현업 부서에 배치

→ '집기분'

▼ 참고

DSCoE (Data Science Center of Excellence)

- 풀네임: Data Science Center of Excellence
- 의미: 기업이나 조직 내에서 데이터 과학/빅데이터/AI 역량을 집중·전문화하는 조직
- 주요 역할
 1. 데이터 분석·머신러닝·AI 모델 개발
 2. 빅데이터 플랫폼, 데이터 거버넌스 구축
 3. 사내 데이터 활용 교육·컨설팅
 4. 데이터 기반 의사결정 문화 확산

2. 빅데이터 기술 및 제도

-빅데이터

- 빅데이터 플랫폼

- 데이터의 수집부터 저장, 처리, 분석 등의 파이프라인 전 과정을 통합적으로 제공하는 환경

- 빅데이터 플랫폼의 계층구조

(1) 소프트웨어 계층

- 데이터 수집 및 정제, 데이터 처리 및 분석, 사용자/서비스 관리

(2) 플랫폼 계층

- 데이터 및 자원의 관리, 작업 스케줄링, 프로파일링

(3) 인프라스트럭처 계층

- 자원의 배치 및 관리, 저장장치 및 네트워크 관리

→ 소프트웨어가 상위 계층, 인프라스트럭처가 하위 계층



- 빅데이터와 인공지능

- 인공지능, 머신러닝, 딥러닝의 관계
 - 딥러닝 < 머신러닝 < 인공지능



인공신경망>사람의 뇌를 모방

- 머신러닝의 종류
 - 지도학습 : 정답을 알려주고 학습시키는 방법
 - 비지도학습 : 정답을 가르쳐주지 않고 학습시키는 방법
 - 준지도학습 : 정답이 있는 데이터와 정답이 없는 데이터를 모두 활용하는 방법
 - 강화학습 : 에이전트가 보상을 받기 위해 학습하는 방법 ex)알파고(바둑을 이기기 위해)
- 약인공지능, 강인공지능
 - 약인공지능 : 주어진 조건에서만 동작하는 인공지능
 - 강인공지능 : 인간과 동일한 사고가 가능한 인공지능
 - 초인공지능 : 기술적 특이점을 뛰어넘어 인간을 초월한 인공지능
- 경량 딥러닝 학습 기법
 - 전이학습 : 사전에 훈련된 모델을 재사용하는 학습 방식
 - Fine-Tuning : 학습된 모델을 특정 타겟에 맞게 재조정하는 방법
 - 지식증류 : Teacher Network의 지식을 Student Network에 전달하는 방법

- 최신 인공지능 기술동향

- (1) AutoML : 머신러닝 프로세스를 자동화
- (2) MLOps : DevOps를 머신러닝 프로세스에 적용
- (3) XAI(eXplainable AI) : 설명 가능한 인공지능 기술
- (4) 생성형 AI : 학습한 데이터를 바탕으로 새로운 콘텐츠를 생성하는 기술
 - 텍스트 생성(ChatGPT, BERT), 이미지 생성(Midjourney, Stable, Diffusion), 비디오 생성
 - LLM(Large Language Model) : 수십억 개의 파라미터가 학습된 거대 언어 모델
 - Diffusion Models : 확률적 프로세스를 이용하여 새로운 데이터를 생성하는 방법

- 개인정보 법제도

- 데이터 3법

- (1) 개인정보보호법
- (2) 정보통신망 이용 촉진 및 정보보호 등에 관한 법률(정보통신망법)
- (3) 신용정보의 이용 및 보호에 관한 법률(신용정보법)
→ '개정법'

- 데이터 3법 주요 특징

- 가명정보의 개념 도입 (통계 작성, 연구, 공익적 기록보존 목적 하에 동의 없이 활용 가능)
- 개인정보보호 거버넌스 체계 효율화
- 개인정보처리자 책임 강화
- 개인정보의 판단기준 명확화

- 개인정보, 가명정보, 익명정보

- (1) 개인정보 : 개인을 알아볼 수 있는 정보, 동의를 받아 활용 가능 (홍길동, 33세)
- (2) 가명정보 : 가명처리를 통해 추가정보 없이 특정 불가 (홍OO, 30대 초반)
- (3) 익명정보 : 더 이상 개인을 알아볼 수 없는 정보, 제한 없이 자유롭게 사용 (OOO, 30대)

- 개인정보 비식별 조치 가이드 라인

- 사전검토 → 비식별조치(총계, 삭제, 마스킹) → 적정성평가(k-익명성, l-다양성, t-근접성) → 사후관리

- 개인정보 활용

- 위기 요인과 통제방안

- (1) 사생활 침해 : SNS에 올린 데이터가 사생활 침해
→ 제공자에서 사용자 책임으로 전환
- (2) 책임 원칙 훼손 : 범죄 예측 프로그램으로 예측하여 체포하는 문제
→ 결과에 대해서만 책임
- (3) 데이터의 오용 : 분석 결과가 항상 옳은 것은 아님
→ 알고리즘을 해석가능한 알고리즘리스트 필요
*알고리즘리스트 : 부당하게 피해가 발생한 사람들을 구제하는 전문인력

데이터분석계획

1. 분석방안수립

- 분석 로드맵 설정

- 분석 대상과 방법
 - 4가지 유형을 **넘나들며** 분석을 수행

대상 방법	Known	UnKnown
Known	최적화 (Optimization)	통찰 (Insight)
Un-Known	솔루션 (Solution)	발견 (Discovery)

→ 무엇을 먹고싶은지? 어떻게 조리해야하는지의 예시로 설명

• 분석기획방안

구분	과제 중심적 접근	장기적 마스터 플랜
목적	빠르게 해결	지속적 분석 관점 해결
1차 목표	Speed & Test	Accuracy & Deploy
과제 유형	Quick & Win	Long Term View
접근 방식	Problem Solving	Problem Definition

- 다음중 과제 중심적 접근이 아닌 것은?

• IT 프로젝트의 우선순위 선정 기준

- (1) 전략적 중요도 : 전략적 필요성, 시급성
- (2) 실행 용이성 : 투자 용이성, 기술 용이성

• 데이터 분석 프로젝트의 우선순위 선정 기준

- (1) **시급성** 관점 : 비즈니스 효과 (Return), **KPI**(핵심성과지표) - Value
- (2) **난이도** 관점 : 투자비용 요소(Investment) - Volume, Variety, Velocity

(어려움)	1	2
난이도	3	4
(쉬움)	(현재)	(미래)

- 시급성 중요시 : 3 → 4 → 2

- 난이도 중요시 : 3→1→2

→ 3과 2는 앞 뒤로 고정하고 가운데만 변경

- 의사결정을 가로막는 요소

- 고정관념, 편향된 생각
- **프레이밍 효과** : 동일 상황임에도 개인의 판단, 결정이 달라짐

- 분석 문제 정의

- 하향식 접근 방법

- 문제가 주어지고 해답을 찾기 위해 진행
- **문제 탐색** → 문제 정의 → 해결방안 → **타당성 검토**

(1) 문제탐색

1) 빠짐없이 문제를 도출하고 식별하며, 솔루션 초점보다는 가치에 초점

2) 비즈니스 모델 캔버스 단순화 측면 : **업무, 제품, 고객, 규제와 감사, 지원인프라**

비즈니스 모델 캔버스 단순화 측면(9가지) → 5가지로 축약 하향식

→ **'지원인프라 업무 중에 고객이 제품을 규제와 감사했다.'**

3) 관점

- 거시적 관점 : **STEEP**(사회, 기술, 경제, 환경, 정치)

- 경쟁자 확대 관점 : 대체자, 경쟁자, 신규 진입자

- 시장의 니즈 탐색 관점 : 고객, 채널, 영향자

(2)문제 정의

- 비즈니스 문제를 데이터 문제로 변화하여 정의

(3) 해결방안

- 기존 시스템 활용, 시스템 고도화, 인적 자원 확보, 아웃소싱 등

(4) 타당성 검토

- 경제적 타당성 : **비용대비 편익** 분석관점 접근

- 데이터 타당성 : **데이터 존재여부, 분석역량**이 필요

- 기술적 타당성 : 역량 확보 방안 사전에 수립

- 상향식 접근 방법

- 문제 정의 자체가 어려울 때, 사물을 그대로 인식하는 **What 관점**
- 주로 **비지도 학습** 활용

- 혼합접근 방법

(1) 발산 단계 : **상향식 접근 방법**으로서, 가능한 방안들을 도출

(2) 수렴 단계 : **하향식 접근 방법**으로서, 도출된 방안들을 분석



- 디자인 싱킹

- 사용자에게 공감으로 시작해서 아이디어 발산/수렴 과정을 통한 피드백으로 발전하는 과정
- 공감하기 → 문제정의 → 아이디어 도출 → 프로토타입 → 테스트

- 데이터 분석 방안

- 분석 방법론의 구성요소

- 절차, 방법, 도구와 기법, 템플릿과 산출물

- 분석 과제에서 고려해야할 5가지 요소

- 데이터 크기, 속도, 데이터 복잡도, 분석 복잡도, 정확도 / 정밀도

*정확도(Accuracy)와 정밀도(Precision)는 Trade-Off 관계

→ 여기에서의 정확도와 정밀도는 4과목의 오분류표에서의 평가지표와는 다른 개념

→ 정확도: 모델이 얼마나 정확 / 정밀도 : 모델 반복했을 때 얼마나 동일하게 나오나

- 프로젝트 관리 지식 체계 10가지 영역

- 통합, 범위, 시간(일정), 원가, 품질, 인적자원, 의사소통, 리스크(위험), 조달(아웃소싱), 이해관계자

→ '이범통이 의사에서 시원한 조리품을 먹었다.'

- 분석 방법론 모델

(1) 계층적 프로세스 모델 : 단계(Baseline으로 관리) → 태스크 → 스텝(단기간 수행 WorkPackage)

(2) 폭포수 모델 : 이전 단계 완료되어야 다음 단계 진행 (Top-Down)

(3) 나선형 모델 : 여러 개발과정 거쳐 점진적으로 완성, 위험요소 제거 초점

(4) 프로토타입 모델 : 일부분(프로토타입)을 우선 개발하고 보완

(5) 반복적 모델

- 증분형 모형 : 전체 시스템을 작은 기능 단위로 나누어 개발

- 진화형 모형 : 핵심 부분을 개발한 후 요구사항을 반영하여 진화

(6) 애자일 : 짧은 개발 주기를 가지고 고객 피드백을 지속적으로 반영하여 반복적인 개발

- KDD 분석 방법론

- 데이터선택 → 전처리 → 변환 → 마이닝 → 결과 평가

1) 데이터선택 : 원시데이터(Raw Data)나 DB에서 필요한 데이터 선택

2) 전처리 : 이상값, 잡음 식별 및 데이터 가공

3) 변환 : 변수 선택 및 차원 축소

4) 마이닝 : 알고리즘을 선택하여 분석 수행

5) 결과평가 : 결과에 대한 해석, 결과가 충족되지 않으면 절차를 반복 수행

- Crisp-DM 분석 방법론

- 업무 이해 → 데이터 이해 → 데이터 준비 → 모델링 → 평가 → 전개

→ '업데이트모델평가전'

- 1) 업무 이해 : 업무 목적 파악, 상황파악, 목표 설정, 프로젝트 계획 수립
- 2) 데이터 이해 : 초기 데이터 수집, 기술 분석, EDA, 데이터 품질 확인
- 3) 데이터 준비 : 데이터 셋 선택 및 정제, 통합
- 4) 모델링 : 모델링 기법 선택, 테스트 계획 설계, **모델 작성 및 평가**
→ 모델 작성 및 평가 > 평가라는 단어가 들어갔지만, 모델링에서 진행
- 5) 평가 : **분석결과 평가, 모델링 과정 평가, 모델 적용성 평가**
- 6) 전개: 전개 계획, 모니터링 및 유지보수 계획 수립, 프로젝트 종료 보고서 작성, 프로젝트 리뷰
* 평가 → 전개에서 **위대한 실패**(업무 이해로 다시 돌아감) 발생 가능
→ 순서, 세부내용 암기

• SEMMA 분석 방법론

- Sample → Explore → Modify → Model → Assess
- 1) Sample : 분석 대상 데이터 추출
 - 2) Explore : 탐색하고 오류 확인
 - 3) Modify : 데이터의 변환
 - 4) Model : 알고리즘 적용
 - 5) Assess : 모델의 평가 및 검증

• ★빅데이터 분석 방법론



→ 'PPADD'

1) 분석 기획

- 프로젝트 위험계획 수립 : **회피, 전이, 완화, 수용**

→ '회전완수'

2) 데이터 준비

- 데이터 스토어 설계 : 정형, 비정형, 반정형 데이터에 따른 효율적 저장소를 설계

3) 데이터 분석

- 분석용 데이터 준비 : 추가적인 데이터 확보 필요 시, 데이터 준비 단계로 다시 진행

- 모델링 : 알고리즘 설명서는 상세히 작성

- 모델 평가 및 검증 : 성능이 저조한 모델은 튜닝 작업 수행

• 분석 거버넌스 체계 구성요소

- 조직, 프로세스, 시스템, 데이터, 분석관련 교육 및 마인드 육성체계

→ '시조프로마인드'

• 데이터 분석 수준 진단

(1) 분석 준비도

분석적 업무파악	인력 및 조직	분석기법
발생한 사실 분석업무 예측분석 업무 시뮬레이션 분석업무 분석업무 정기적 개선	분석전문가 직무 존재 분석전문가 교육훈련 프로그램 관리자들의 기본적 분석능력 전사 분석업무 총괄 조직 존재 경영진 분석업무 이해능력	업무별 적합한 분석기법 사용 분석업무 도입 방법론 분석기법 라이브러리 분석기법 효과성 평가 분석기법 정기적 개선
분석 데이터	분석 문화	IT 인프라
분석업무를 위한 데이터 중분성 분석업무를 위한 데이터 신뢰성 분석업무를 위한 데이터 적시성 비구조적 데이터 관리 외부 데이터 활용 체계 마스터데이터 관리(MDM)	사실에 근거한 의사결정 관리자의 데이터 중시 회의 등에서 데이터 활용 경영진의 직관보다 데이터 데이터 공유 및 협업 문화	운영시스템 데이터 통합 EAL ETL 등 데이터 유통체계 분석전용 서버 및 분석환경 빅데이터 분석환경 통계분석 환경 비주업분석 환경

→ 'IT문데기인파'

다음중 분석준비도에서 고려해야할 것이 아닌 것은?> 내부까지 다 공부

(2) 분석 성숙도 (= CMMI : 국제표준)

- CMMI 모델 기반 (1~5단계)

- 1) 도입 : 환경, 시스템 구축
- 2) 활용 : 업무에 적용
- 3) 확산 : 전사 차원 관리, 공유
- 4) 최적화 : 혁신, 성과향상에 기여

→ '도활확최'

최적화가 될 수록 성숙화

단계	비즈니스 부문	조직 및 역량부분	IT 부문
도입	실적 분석 및 통계 정기 보고 수행 운영 데이터 기반	일부 부서에서 수행 담당자 역량에 의존	데이터 웨어하우스 데이터 마트 ETL/EAI OLAP
활용	미래결과 예측 시뮬레이션 운영 데이터 기반	전용담당부서 수행 분석 기법 도입 관리자가 분석 수행	실시간 대시보드 통계분석 환경
확산	전사성과 실시간 분석 프로세스 혁신 3.0 분석규칙 관리 이벤트 관리	전사 모든 부서 수행 분석 COE 운영 데이터 사이언티스트 확보	빅데이터 관리 환경 시뮬레이션/최적화 비주업 분석 분석 전용 서버
최적화	외부 환경 분석 활용 최적화 업무 적용 실시간 분석 비즈니스 모델 진화	데이터 사이언스 그룹 경영진 분석 활용 전략 연계	분석 협업 환경 분석 Sandbox 프로세스 내재화 빅데이터 분석

• 데이터 분석 성숙도 모델



1) 준비형 : 낮은 준비도, 낮은 성숙도

- 데이터, 인력, 분석업무, 분석기법 적용 안되어 사전 준비 필요

2) 정착형 : 낮은 준비도, 높은 성숙도

- 인력, 조직, 분석업무, 분석기법 등을 제한적으로 사용

3) 도입형 : 높은 준비도, 낮은 성숙도

- 조직 및 인력 등 준비도는 높으나, 분석업무 및 기법 부족

4) 확산형 : 높은 준비도, 높은 성숙도

- 6가지 분석 구성요소를 모두 갖추고 있으며, 지속적 확산이 가능

→ '도준정확' 4사분면부터 시계방향(역순)으로 암기

• 분석지원 인프라 방안 수립

- 확장성을 고려한 플랫폼 구조 적용 (중앙집중적 관리)


(1) 분석 플랫폼 구성요소

1) 광의의 분석 플랫폼 : 분석 서비스 제공엔진, 분석 어플리케이션, 분석 서비스 API, 하드웨어, OS

2) 협의의 분석 플랫폼 : 데이터 처리 프레임워크, 분석엔진, 분석 라이브러리

→ 광의의 분석 플랫폼은 협의의 분석 플랫폼 요소들을 포함하는 개념

→ 두 개 구분 광의 > 사용자 쪽



• 데이터 거버넌스

(1) 데이터 거버넌스

- 전사 차원에서 데이터에 대해 표준화된 관리 체계 수립

1) 구성요소 : **원칙, 조직, 프로세스**

→ '**원조프**'

2) 중요 관리대상

- 마스터데이터 : 자료 처리에 기준이 되는 자료

- 메타데이터 : 다른 데이터를 설명해주는 데이터

- 데이터 사전 : DB에 저장된 정보를 요약

(2) 데이터 거버넌스 체계

1) 데이터 표준화 : 메타데이터 및 사전 **구축**

2) 데이터 관리 체계 : **효율성**을 위함

3) 데이터 저장소 관리 : **저장소** 구성

4) 표준화 활동 : **모니터링, 표준 개선 활동**

• 빅데이터 거버넌스

- 데이터 거버넌스 체계 + 빅데이터 효율적 관리, 데이터 최적화, 정보보호, 데이터 카테고리 별 관리책임자 지정 등을 포함

데이터 수집 및 저장 계획

1. 데이터 수집 및 전환

- 데이터 수집

• 데이터 수집 기술

- (1) ★ETL : **Extraction, Transformation, Load** 3단계를 통하여 DB 시스템에 데이터 적재
- (2) FTP : TCP / IP 네트워크에서 **컴퓨터들 간의 파일을 교환**하기 위한 통신 규약
- (3) API : 응용 프로그램에서 다른 프로그램으로 데이터를 전송할 수 있는 인터페이스
- (4) 아파치 스쿱(Scoop) : RDBMS와 하둡간의 대용량 데이터를 전송하는 도구
- (5) 아파치 플럼(Flume) : 대량의 로그 데이터를 효율적으로 수집, 전송하는 분산형 서비스 시스템
- (6) 웹 크롤링 : **웹 상의 데이터를 탐색하고 수집**하는 기법

- 데이터 유형 및 속성 파악

• 데이터의 유형

(1) 정성적, 정량적

- 정량적 데이터 : 자료를 수치화 - 수치, 기호(온도, 풍속)

- 정성적 데이터 : 자료의 특징을 풀어 설명 - 언어, 문자 (기상특보, 주관식 설문 응답)

(2) ★정형(Frame), 반정형(Frame X, 메타데이터 포함) , 비정형

- 정형 데이터 : 정보 형태가 정해짐(관계형 DB, 엑셀 - 스프레시트 , CSV)

- **반정형 데이터** : 데이터를 설명하는 **메타데이터**를 포함 (HTML, XML, JSON, RDF)

- 비정형 데이터 : 형태가 정해지지 않음 (SNS, 유튜브, 음원) → *NoSQL에 저장*

(3) 가역, 불가역 데이터

- 가역 데이터 : 원본으로 일정 수준으로 복원이 가능

- 불가역 데이터 : 원본으로 복원이 불가능

(4) 내부, 외부 데이터

- 내부 데이터 : 운영, 비즈니스 활동, 고객 상호작용 등에서 발생하는 조직 내부에서 생성된 데이터
- 외부 데이터 : 외부 기관이나 정부에서 데이터를 수집해야 하며, 검증이나 가공이 필요

• 데이터의 척도 구분

(1) 질적 척도

- 명목척도 : 어느 집단에 속하는지 나타내는 자료 (대학교, 성별)
- 순서척도 (서열척도) : 서열 관계가 존재하는 자료 (학년, 순위)

(2) 양적 척도

- 등간척도(구간척도) : **구간 사이 간격이 의미**가 있으며 덧셈과 뺄셈만 가능 (온도, 지수 등)
- 비율척도 : **절대적 기준 0이 존재**하고 사칙연산 가능한 자료 (무게, 나이 등)

- 데이터 비식별화

• 개인정보 비식별화

(1) 가명처리(홍길동, 35세 → 임꺽정, 30세)

- 휴리스틱 가명화(사람의 판단), 암호화, 교환 방법

(2) 총계처리(홍길동 170cm, 임꺽정 180cm → 평균키 175cm)

- 부분총계, 라운딩(올림, 내림, 반올림), 재배열(**타인 정보와 섞어 전체 정보 손상 없음**)

(3) 데이터 삭제 (주민등록번호 901111-1234567 → 90년대생, 남자)

- 식별자 삭제, 식별자 부분삭제, 레코드 삭제, 식별요소 전부삭제

(4) 데이터 범주화 (홍길동, 35세 → 홍길동, 30~40세)

- 감주치(평균, 범주로 변환), 랜덤 라운딩, 범위 방법, 제어 라운딩

(5) 데이터 마스킹(홍길동, 35세 → 홍OO, 35세)

- 임의 **잡음(노이즈)** 추가, 공백과 대체

• 프라이버시 보호 모델

→ *어려우면 사례 문제 나올 수 있음 > 환자 데이터(구글링, 지피티 검색)*

→ (1)→ (3)으로 갈 수록 보호성 up

(1) k-익명성

- 같은 값이 존재하도록 하여 다른 정보로 결합할 수 없도록 함
- **연결공격**으로부터 보호

(2) i-다양성

- 민감한 정보의 다양성을 높여 추론 가능성을 낮춤
- **동질성 공격**과 **배경 지식에 의한 공격**으로부터 보호

(3) t-근접성

- 민감한 정보의 분포를 낮추어 추론 가능성을 더욱 낮춤
- **썰림 공격**이나 **유사성 공격**으로부터 보호

▼ 사례

프라이버시 보호 모델 (Privacy Protection Models)

1) 익명화(Anonymization)

- 직접적으로 개인을 식별할 수 있는 정보(이름, 주민번호, 전화번호 등)를 제거하거나 변형
- 환자 데이터 예시:
 - “홍길동(서울시 강남구, 010-1234-5678)” → “환자 A (서울시, 연락처 제거)”

2) 가명화(Pseudonymization)

- 실제 이름을 **가짜 식별자(ID, 코드)** 로 대체
- 데이터 분석은 가능하지만, 원본을 역추적하기 어렵게 함
- 환자 데이터 예시:
 - “환자ID: P001, 나이: 45, 질병: 당뇨” (이름 대신 ID 사용)

3) k-익명성 (k-Anonymity)

- 특정 개인이 최소 **k명 이상 그룹 내에 섞여 있도록 보장**
- 환자 데이터 예시:
 - 나이 45세, 서울 거주, 여성 → 너무 구체적이라 한 사람만 특정될 수 있음
 - → “40대, 수도권, 여성” 으로 일반화하여 최소 5명 이상 그룹에 속하도록 함

4) l-다양성 (l-Diversity)

- k-익명성 보완: 같은 그룹 안에서도 **민감 속성(질병명 등)이 다양**해야 함
- 환자 데이터 예시:
 - “40대 여성 5명” 그룹이 모두 “유방암” 환자라면 여전히 유출 위험 존재
 - → 그룹 내 최소 2~3개 이상의 질병 진단이 포함되도록 설계

5) t-근접성 (t-Closeness)

- 그룹 내 민감 속성 분포가 전체 데이터 분포와 **유사(tolerance)** 해야 함
- 환자 데이터 예시:
 - 전체 환자의 당뇨 비율이 20%인데, 특정 그룹에서 80%가 당뇨라면 위험
 - → 그룹 내 분포가 전체와 큰 차이가 없도록 제한

6) 차등 프라이버시 (Differential Privacy)

- 데이터 질의/분석 시 **노이즈(무작위 값)** 를 추가하여 개인 정보 유출 방지
- 환자 데이터 예시:
 - “서울 거주 당뇨 환자 수 = 103명” → 실제로는 100명, ± 노이즈 3명 추가
 - → 개별 환자가 포함되었는지 알아낼 수 없음



요약: 환자 데이터 보호 방법

- **익명화/가명화** → 직접 신원 노출 차단
- **k-익명성, l-다양성, t-근접성** → 간접 식별 방지
- **차등 프라이버시** → 분석·통계 활용 시 안전하게 데이터 제공
- **차등정보보호**
 - 개인 정보를 **다른 수많은 데이터와 조합(노이즈)**하여, 개인정보를 침해하지 않고 정보 패턴 발견
 - **섭동**(오차를 활용한 교란), 이중지수분포 활용 등의 기법 적용

모델	개념	환자 데이터 적용 예시
익명화 (Anonymization)	개인을 직접 식별할 수 있는 정보(이름, 주민번호 등)를 제거/일반화	"홍길동(010-1234-5678)" → "환자 A (연락처 제거)"
가명화 (Pseudonymization)	이름 등을 임의 ID나 코드로 대체	"홍길동" → "환자ID: P001"
k-익명성 (k-Anonymity)	특정 개인이 최소 k명 이상 그룹 안에 섞여 있도록 일반화	"45세, 서울 강남구" → "40대, 수도권" (5명 이상 그룹)
l-다양성 (l-Diversity)	그룹 내 민감 속성(질병 등)이 다양해야 함	"40대 여성 그룹" 안에 유방암·당뇨·고혈압 환자 섞이도록
t-근접성 (t-Closeness)	그룹 내 속성 분포가 전체 데이터 분포와 유사해야 함	전체 당뇨 환자 비율 20%라면, 그룹 내에서도 유사한 비율 유지
차등 프라이버시 (Differential Privacy)	데이터 조회 시 무작위 노이즈를 추가해 개인 유출 방지	실제 당뇨 환자 100명 → 통계 결과 103명 (± 노이즈 추가)

- 데이터 품질 검증

• 데이터 품질 기준

- (1) 완전성: 필요한 데이터가 빠짐없이 존재하는가?
- (2) 정확성: 데이터가 실제 값이랑 일치하는가?
- (3) 일관성: 여러 시스템에서 데이터가 동일한가?
- (4) 최신성: 데이터가 최신 상태를 반영하는가?
- (5) 유효성: 사전에 약속된 형식을 만족하는가?
- (6) 접근성: 필요한 사용자가 쉽게 접근이 가능한가?
- (7) 보안성: 데이터가 안전하게 보호되고 있는가?

• 데이터 품질 진단 및 개선 절차

- (1) **진단 절차**: 진단 대상 정의 → 품질 진단 실시 → 진단 결과 분석
 - 1) 진단 대상 정의: 품질 진단 수요조사, 품질 진단 현황분석, 품질 진단 추진계획 수립
 - 2) 품질 진단 실시: 품질 진단 준비, 품질 진단 수행
 - 3) 진단 결과 분석: 오류원인 분석, 업무 영향 분석, 개선 기회 도출
- (2) **개선 절차**: 개선 계획 수립 → 개선 수행 → 품질 통제
 - 1) 개선 계획 수립: 품질개선 방향 정의, 품질개선 추진계획 수립
 - 2) 개선 수행: 품질개선 준비, 품질개선 수행
 - 3) 품질 통제: 결과 평가, 품질 목표 관리, 품질 통제 실시

2. 데이터 적재 및 저장

• 분산 파일 시스템

- (1) **HDFS**(하둡 분산파일 시스템)
 - 슬레이브 관리하는 마스터노드(=네임노드)와 데이터 처리하는 슬레이브노드(=데이터노드)로 구성
 - 64MB의 여러 블록으로 분산 저장
 - 분산 처리를 통하여 시스템의 과부하 및 병목 현상 해소
 - 오픈 소스로서 무료 사용 가능
- (2) **GFS**

- 구글의 데이터 처리를 위해 설계된 분산 파일 시스템
- 마스터(관리/통제), 청크 서버(물리 저장소 처리), 클라이언트(어플리케이션)로 구성
- (3) 그 외 파일 시스템
- Ceph, 아마존 S3 등
- 분산 파일 시스템과 분산 데이터베이스는 구분되는 개념임

• 데이터베이스

- (1) 관계형 데이터베이스 : 정형 데이터의 처리, 데이터의 **무결성 보장** (MySQL, MariaDB, Oracle)
- *무결성 : 데이터가 정확하고 신뢰할 수 있으며, 조작되지 않고 원본 상태로 보존되는 것
- (2) **NoSQL 데이터베이스** : 비정형데이터의 처리, 확장성과 가용성에 이점
- 1) 키-값 데이터베이스 : 가장 단순한 구조로, 속도가 빠름 (Redis, VoldMorte)
- 2) 열 데이터베이스 : 열 단위로 저장되므로, 압축 및 확장성에 유리 (Hbase, Big Table, Cassandra)
- 3) 문서 데이터베이스 : 문서를 트리 구조로 저장하거나 검색 (MongoDB, CouchDB)
- 4) 그래프 데이터베이스 : 노드로 표현되며 유연하고 유지보수 용이 (Neo4j, OrientDB)

• 저장소(스토리지)

- (1) DAS(Direct Attached Storage) : 서버와 저장소가 물리적으로 직접 연결
- (2) NAS(Network Attached Storage) : LAN 네트워크를 통해 여러 컴퓨터가 동일 저장소 공유
- (3) SAN(Storage Area Network) : 특수 목적용 고속 네트워크와 스위치를 통해 연결


• 병렬 DBMS

- 데이터 병렬 처리(**동시처리**)를 활용하여 성능 개선
- 공유 메모리, 공유 디스크, Shared Nothing 구조를 가짐
- 종류 : VoltDB, SAP HANA, Vertica 등

• 데이터웨어하우스, 데이터마트, 데이터레이크

(1) ★데이터 웨어하우스(DW)의 특징 → (大DB)

- 주제지향성: 분석목적 설정이 중요
- 데이터 통합: 일관화 된 형식으로 저장
- 시계열성 : 히스토리를 가진 데이터
- **비휘발성** : 읽기전용 - 수시로 변하지 않음




(2) 데이터 웨어하우스의 구성요소

- ETL(Extraction, Transform, Load) > 추출하고(ODS에 임시로 저장), 변환하고, 적재해
- **ODS(Operational Data Stote)** : 다양한 DBMS에서 추출한 데이터를 임시 저장

(3) 데이터 마트(DM)

- 데이터 웨어하우스의 한 분야로 **특정 목적을 위해 사용** (소규모 데이터웨어하우스)



*DW : 전사적 / DM : 특정부서

(4) 데이터 레이크

- 비정형 데이터를 저장하며 하둡과 연계하여 처리

*호수에 던져둠