

2

2과목 빅데이터 탐색

- 2 과목(빅데이터 탐색) 주요 내용		
데이터 전처리	데이터 정제	데이터 정제
		데이터 결측값 처리
		데이터 이상값 처리
	분석 변수 처리	변수 선택
		차원 축소
		파생변수 생성
데이터 탐색	데이터 탐색 기초	변수 변환
		불균형 데이터 처리
		데이터 탐색 개요
	고급 데이터 탐색	상관관계 분석
		기초통계량 추출 및 이해
		시각적 데이터 탐색
통계기법 이해	기술통계	시간대 데이터 탐색
		다변량 데이터 탐색
		비정형 데이터 탐색
	추론통계	데이터 요약
		표본추출
		확률분포

1과목 : 데이터 분석 방법론 > 데이터 수집 > 저장

2과목 : 데이터를 탐색해보기 (어떻게 생겨먹었는지)

전처리 수행해서 모델링을 수행할 수 있도록!

> 통계/수학적 학습 or 암기

2-3-4과목 연관 한번에 공부 하고 기출 같이 보기

데이터 전처리

1. 데이터 정제

- 데이터 정제

• 데이터의 종류

(1) 단변량 데이터 : 데이터의 특성이 하나인 데이터 (집값 ← 수도권 거리)

(2) 다변량 데이터 : 데이터의 특성이 두 개 이상인 데이터 (집값 ← 수도권 거리, 고속도로, 지하철, 버스, 평수)

(3) 시계열 데이터 : 시간 순서에 따라 관측된 데이터 (=종단면적 데이터) → 주식, 비트코인, 기온

*종단면적 데이터(여러 시점에 측정) ↔ 횡단면적 데이터(한 시점에 측정) / 패널데이터(종단+횡단)


• 데이터 정제 → 데이터를 깨끗하게 만든다

(1) 집계 : 데이터를 요약 (합계, 평균, 분산, 개수, 최대/최소)

(2) 일반화 : 데이터의 일반적인 특성 추출

(3) 정규화 : 데이터를 정해진 구간으로 조정하여 상대적 차이 제거

(4) **평활화** : 잡음을 제거하여 추세를 부드럽게 만듦 (이동평균법, 지수평활법) → **시계열 분석**



빨간색>잡음 제거

- 데이터 결측값 처리

• 결측치 종류

- 존재하지 않는 데이터, null/NA로 표시

(1) 완전 무작위 결측 (MCAR)

- 다른 변수들과 아무런 상관없는 경우
- 예) 입력실수, 전산오류

(2) 무작위 결측 (MAR)

- 특정 변수와 관련되어 발생하였지만, 결과와는 관계가 없는 경우
- 예) 특정 정치 성향 유권자들의 응답률이 낮으나, 정당의 득표율이 낮은 것은 아님

(3) 비 무작위 결측 (MNAR)

- 결측치가 변수의 결과에 상관이 있는 경우
- 예) 소득이 낮은 응답자들의 응답률이 낮음

• 결측값 처리

(1) 완전분석법 : 결측값 가지는 데이터 삭제

(2) 평균 대체법(=비조건부 평균 대체) : 단순 평균으로 대체

(3) 회귀 대체법(=조건부 평균 대체) : 회귀 분석의 결과로 대체

(4) 단순 확률 대체법 : 확률적으로 선택하여 대체

- Nearest Neighbor : 바로 가까운 응답으로 대체
- Hot-Deck : 현재 데이터 셋에서 비슷한 성향으로 대체
- Cold-Deck : 유사한 외부 출처에서 비슷한 성향으로 대체

(5) 다중 대체법 : 여러 번 대체 (**대치** → **분석** → **결합**)


- 데이터 이상값 처리

• 이상값 처리

- 극단적으로 크거나 작은 값이며, 의미 있는 데이터 일수도 있음 (체중 3kg)
- 이상값을 항상 제거하는 것은 아님**

(1) ESD(Extreme Studentized Deviation)

- 평균으로부터 표준편차의 3배 넘어가는 데이터는 이상값으로 판단




→ 위 그래프 정규분포(평균에 가까울 수록 사람이 많음)

(2) 사분위수

- $Q1 - 1.5IQR$ 보다 작거나, $Q3 + 1.5IQR$ 보다 크면 이상값으로 판단
- 최솟값, 1~3사분위값, 최댓값 등을 표현하며, 평균값은 표현하지 않음


*Q2 : 중간값(50%)

* $Q3 - Q1 = IQR$



(2) 사분위수

- $Q1 - 1.5IQR$ 보다 작거나, $Q3 + 1.5IQR$ 보다 크면 이상값으로 판단
- 최솟값, 1~3사분위값, 최댓값 등을 표현하며, 평균값은 표현하지 않음



사분위수에서는 평균을 알 수 없다.

(3) Z-Score

- 데이터를 정규화(평균0, 표준편차 1) 후, 일정 임계값을 초과할 경우 이상값으로 판단

*이 개념 수치형 변수 변환에서도 나옴

(4) DBScan

- 밀도를 이용하여 밀도가 적은 부분의 데이터를 이상값으로 판단

2. 분석 변수 처리

- 변수 선택

• 변수 선택 방법

- (1) 전진선택법 : 변수를 하나씩 추가해 나가는 방법
- (2) 후진제거법 : 변수를 하나씩 제거해 나가는 방법
- (3) 단계별 선택법 : 전진선택법 + 후진제거법으로 변수 추가할 때 벌점을 고려

상관계수 매트릭스 분석				
	X1	X2	X3	X4
X1	1.0	0.21	-0.31	0.95
X2	0.21	1.0	0.02	0.13
X3	-0.31	0.02	1.0	-0.05
X4	0.95	0.13	-0.05	1.0

- X1과 X4가 높은 상관계수를 가지므로, 둘 중 하나의 변수 제거


* 상관계수는 -1 ~ 1사이의 값을 가지며, -1은 음의상관관계, 1은 양의상관관계를 의미

*자기자신 = 1

*상관계수 매트릭스 이용하여 변수 제거 가능 > 상관계수가 높으면 변수 하나 제거 가능

- 차원 축소

집값 ← 수도권거리, 고속도로, 지하철, 버스, 평수



고차원의 데이터를 저차원으로 줄임(데이터 변수의 개수를 줄임)

왜?

데이터의 변수가 늘어나게 되면 차원이 커지거나, 독립변수 간 강한 상관관계를 보일 경우(다중공선성이 있을 경우) 모델의 정확도가 떨어져 신뢰도가 떨어지기 때문에 변수의 개수를 줄이는 방법으로 모델의 정확도를 높이기 위해서이다.

• 차원의 저주

- 데이터 학습 시 차원이 높아질수록 알고리즘의 성능이 저하되는 현상 (데이터를 많이 채워야하기 때문에)

• 차원 축소의 효과

- 차원의 저주 해소, 데이터 시각화, 노이즈 제거, 데이터 압축, 성능 향상, 특징 추출, 계산 비용 절감
- 시각화 가능 > 5차원은 못그림, 3차원만 되어도 그라카 가능

♥

- ★★차원 축소 기법 - 모든 시험에서 출제가 된다 / 종류 多

- 가장 많이 출제 → 주성분 분석

(1) 선형 차원 축소 기법

1) ★★★주성분 분석 (PCA)

- 분산이 최대화되는 방향으로 차원을 축소

2) 선형판별분석 - (LDA : Linear Discriminant Analysis)

- 분류에서 클래스 간 분산을 최대화하면서 차원을 축소하는 기법

3) 독립성분분석 - (ICA : Independent Component Analysis)

- 서로 독립적인 성분을 찾아 차원 축소

4) 특이값 분해 - (SVD : Singular Value Decomposition)

- $m \times n$ 크기의 비정방행렬 A 를 행렬 분해 ($A = U \Sigma V^T$)
 - U 는 $m \times m$ 직교행렬, Σ 는 $m \times n$ 대각행렬, V^T 는 $n \times n$ 직교행렬

5) 요인분석(Factor Analysis)

- 관측된 변수들을 몇 개의 잠재 요인으로 축소하는 방법

- 심리학, 사회과학 등에서 잠재 변수의 해석이 필요한 경우

(2) 비선형 차원 축소 기법

1) 다차원척도법 (MDS : Multi-Dimensional Scaling)

- 데이터 간 거리정보의 근접성을 보존하는 차원 축소

- Stress 함수의 값이 최소가 되도록 구성

2) t-SNE(t-Distributed Stochastic Neighbor Embedding)

- 고차원 데이터간 거리 정보를 확률적으로 유지하여 차원 축소

- 데이터의 복잡한 비선형 패턴을 시각화 하며, 이미지나 텍스트 데이터에 적합

3) UMAP(Uniform Manifold Approximation and Projection)

- t-SNE와 유사한 비선형 차원 축소 기법으로, 구조적 패턴을 보존

- 대규모 데이터에서 빠르게 적용 가능

4) AutoEncoder

- 신경망을 활용한 차원 축소 기법으로 데이터를 압축 후 다시 복원하는 학습

여유 있으면 지피티, 구글로 학습 추천

MDS전(다차원 척도법) ↔ t-SNE 비교

▼ 추가

차원 축소 기법 주요 분류

1. 선형 기반 기법

- 데이터가 선형적으로 잘 표현될 때 효과적
- 대표적으로 PCA, LDA

1. PCA (Principal Component Analysis, 주성분 분석)

- 데이터의 분산을 가장 잘 설명하는 새 축(주성분) 을 찾아 차원을 줄임
- 가장 널리 쓰이는 차원 축소 기법
- 예: 100차원 유전자 데이터 → 2~3차원으로 축소해 시각화

1. LDA (Linear Discriminant Analysis, 선형 판별 분석)

- 분류(label)가 있는 데이터에서 클래스 간 분리를 최대화 하는 축을 찾음
- 지도학습 기반 차원 축소
- 예: 얼굴 인식(사람별 라벨) → 저차원 특징 공간으로 투영

2. 비선형 기반 기법 (Manifold Learning)

- 데이터가 비선형 구조(곡면, 매니폴드)에 놓여 있을 때 유용

1. t-SNE (t-Distributed Stochastic Neighbor Embedding)

- 고차원 데이터의 국소적 구조(근접성)를 보존하면서 저차원에 표현
- 시각화(특히 2D/3D)에서 자주 사용
- 예: 단어 임베딩(Word2Vec) 시각화

1. UMAP (Uniform Manifold Approximation and Projection)

- t-SNE보다 빠르고, 전역 구조도 일정 부분 보존
- 대규모 데이터 시각화에 효과적

1. Isomap

- 데이터 포인트 간 지오데식 거리(곡면 위 최단거리)를 보존하는 방식
- 매니폴드 위의 구조를 잘 드러냄

3. 특징 선택/추출 기반 기법

- 불필요한 특징을 제거(**Feature Selection**) 하거나
- 새로운 특징을 생성(**Feature Extraction**) 하는 방식
- **Feature Selection**: 상관관계, 카이제곱검정, L1 규제(Lasso) 등으로 중요하지 않은 변수 제거
- **Feature Extraction**: 오토인코더(Autoencoder) 같은 딥러닝 기반 기법으로 새로운 압축 표현 생성

4. 딥러닝 기반 기법

- **Autoencoder (자동 인코더)**
 - 신경망을 이용해 입력 데이터를 저차원 잠재공간(latent space)에 압축 후 복원
 - 비선형 구조 데이터 차원 축소에 효과적
 - 예: 이미지 압축·이상탐지
- t-SNE VS MDS



비교 정리

항목	MDS	t-SNE
보존하는 것	거리(전역 구조)	이웃 관계(지역 구조)
방식	선형(주로), 거리 행렬 기반	확률 분포 기반 비선형
장점	전역 거리 관계를 잘 보존	클러스터 구조를 잘 드러냄
단점	비선형 구조 표현 한계	전역 구조 왜곡, 파라미터 민감
활용	사회과학, 심리학, 시장조사 등	이미지·텍스트 임베딩, 딥러닝 결과 시각화

✓ 한 줄 요약

- **MDS** = "거리 지도" (전체 거리 관계 보존, 선형적)
- **t-SNE** = "클러스터 지도" (국소 구조 보존, 비선형적, 시각화에 강점)

- 파생변수 생성

• 요약변수와 파생변수

(1) 요약변수 : 수집된 정보를 종합한 변수로서 **재활용성**이 높음 (1개월간 수입)

(2) 파생변수 : 의미를 부여한 변수, **논리적 타당성** 필요 (고객구매등급)

- 파생변수 생성방법 : 특징 추출, 결합, 부가적 정보 결합, 수학적 변환, **교호작용**의 반영

*교호작용 : **두 개 이상의 독립변수가 상호작용**을 하여, 종속변수에 영향을 미치는 경우

- 변수 변환

• 수치형 자료와 범주형 자료

(1) 수치형 자료 : 키, 몸무게 → **회귀분석**

(2) 범주형 자료 : 혈액형, 성별 → **분류분석**

• 수치형변수 변환

(1) Z-Score 정규화 : **평균 0, 표준편차 1**로 변환 ~ $N(0,1)$

$$Z = \frac{X - \mu}{\sigma}$$

(2) 최소-최대 정규화 : 0에서 1사이로 변환

$$X_{new} = \frac{X - \min(X)}{\max(X) - \min(X)}$$

(3) 로그 변환 : 로그를 취한 값으로 변환, **데이터가 한쪽으로 치우쳐 있을 시 활용**


$$X_{new} = \log X$$

(4) 그 외 변환 기법들 : 지수변환, 제곱근 변환, Box-Cox 변환(**양수 데이터의 비대칭 분포** 시 활용)


*Z-Score 정규화 → $N(0, 1)$ 표준정규분포로 만들어 줌 - 이 개념 이상값 처리에서도 나옴

값에서 평균을 빼고 표준편차를 나눔

값에서 평균을 빼고 표준편차를 나눔




*최소-최대 정규화



*로그변환

정규분포화 된 데이터가 가장 분석하기 좋은 데이터

치우친 데이터에 로그 씌우면 정규분포가 됨



• 범주형 변수 변환

(1) 레이블 인코딩

- 데이터를 정수로 변환

- 오렌지, 바나나, 포도 → 0, 1, 2

단점 → 포도가 오렌지보다 큰 값이 아닌데 (실제로), 큰 값으로 인식

(2) 원-핫 인코딩

- 고유 값에 해당하는 컬럼만 1로 표시하고 나머지는 0으로 표시

- 오렌지, 바나나, 포도 → [1, 0, 0], [0, 1, 0], [0, 0, 1]

레이블 인코딩 보완 but 용량차지

(3) 타깃 인코딩

- 타깃 변수를 평균값으로 변환

• 날짜/시간 변수 변환

(1) 분할: 날짜/시간 데이터를 년, 월, 일, 시, 분 등으로 분할

(2) 파생: 시간대(오전, 오후), 요일 또는 계절 등의 파생변수 생성

- 불균형 데이터 처리

불균형 데이터> 강아지 300장, 고양이 50장일 때

• 불균형 데이터의 처리

(1) 가중치 균형 적용

- 불균형 데이터에 가중치를 주는 방법

(2) 언더샘플링

- 다수 데이터의 일부만 선택

- 방법 : 랜덤 추출법, 계통 추출법, 집락 추출법, 층화 추출법

(3) 오버샘플링

- 소수 데이터를 복사하거나 유사한 데이터를 만드는 방식

- 방법 : SMOTE, ADSYN, ROS



데이터 탐색


1. 데이터 탐색 기초

- 데이터 탐색 개요

- EDA (탐색적 자료 분석)
 - 데이터의 의미를 찾기 위해 **통계, 시각화**를 통해 파악
 - EDA의 4가지 주제
 - 1) 저항성의 강조 : 자료 변동에 민감하지 않음
 - 2) 잔차 계산 : 값들이 주경향으로부터 얼마나 벗어나 있는지 확인하는 척도
 - 3) 자료변수의 재표현 : 원래 변수를 적당한 척도로 변환
 - 4) 그래프를 통한 현시성 : 시각화를 통하여 효율적으로 파악
- '저잔재현'

- 상관관계 분석

- 상관분석
 - 두 변수간의 선형적 관계가 존재하는지 파악하는 분석
 - (1) 단순상관분석: 두 개의 변수가 어느정도 강한관계에 있는가를 측정
 - (2) 다중상관분석: 3개 이상의 변수 간 관계를 측정
 - (3) **편상관관계분석: 제 3의 변수를 통제**한 상태에서 두 변수의 상관관계를 분석
- 상관분석 방법
 - (1) 피어슨 상관분석 : 양적 척도, 연속형 변수, 선형관계 크기 측정
 - (2) ★★스피어만 상관분석 (시험 출제 多) : **서열 척도, 순서형 변수**, 선형/비선형적 관계 나타냄 → 순서를 매길 수 있는 애들



▼ 추가

📌 두 개념 먼저 정리

1. 피어슨 상관계수 (Pearson correlation)

- X와 Y가 **선형(linear)** 관계일 때 잘 작동
- 직선에 가까울수록 ± 1 , 직선에서 벗어나면 값이 작아짐
- 즉, "직선에 얼마나 가까운가"를 보는 지표

2. 스피어만 상관계수 (Spearman correlation)

- **순위(rank) 기반 상관계수**
- X가 커질수록 Y도 계속 커진다면(단조 증가) $\rightarrow +1$
- X가 커질수록 Y가 계속 작아진다면(단조 감소) $\rightarrow -1$
- 직선일 필요 없음. 곡선이어도 계속 증가/감소면 ± 1 가능

📊 그림 설명

- (가)
 - 직선으로 증가 $\rightarrow$ Pearson = +1
 - 순위도 완벽히 증가 $\rightarrow$ Spearman = +1
- (나)
 - 곡선으로 증가 (직선은 아님) $\rightarrow$ Pearson은 직선에서 벗어나므로 약 +0.8
 - 하지만 X가 커질수록 Y도 항상 커짐 $\rightarrow$ Spearman = +1
- (다)
 - 직선으로 감소 $\rightarrow$ Pearson = -1
 - 순위도 완벽히 감소 $\rightarrow$ Spearman = -1
- (라)
 - 곡선으로 감소 $\rightarrow$ Pearson은 직선과 차이가 있어서 약 -0.8
 - 하지만 X가 커질수록 Y는 계속 작아짐 $\rightarrow$ Spearman = -1

✅ 핵심 정리

- **피어슨**: 직선성(linearity)에 민감 $\rightarrow$ 직선일 때만 ± 1
- **스피어만**: 단조성(monotonicity, 계속 증가/감소)에 민감 $\rightarrow$ 곡선이어도 ± 1 가능

👉 따라서 그림 밑에 적힌

“스피어만 계수는 X와 Y가 선형 관계가 아니더라도 +1 혹은 -1이 될 수 있다”
라는 말이 바로 **(나), (라) 그림 같은 경우**를 설명하는 거예요.

♥

- 기초통계량 추출 및 이해

• 기초 통계량

(1) 중심경향성 측면

- 산술평균 : 일반적인 평균 개념으로, 모든 값을 더한 후 데이터 개수로 나눈 값
- 기하평균 : 모든 값들을 곱하고, n 제곱근을 구하는 방식 (비율적 증가율)
- 조화평균 : 역수의 산술평균을 구한 후, 다시 역수를 취하는 방식 (비율 계산)
- 중앙값 : 데이터를 크기 순서로 나열했을 때 중간에 위치한 값
- 최빈값 : 데이터에서 가장 자주 나타나는 값

(2) 분산 정도 측면

- 범위 : 데이터의 최댓값과 최솟값 사이, 전체적인 퍼짐을 나타냄
- 표준편차 : 분산에 제곱근을 취한 값
- 사분위수(IQR) : 데이터의 상위 75%와 하위 25%의 중간 범위
- 변동계수(CV) : 평균대비 표준편차의 비율

(3) 관계 측면

1) 공분산 : 두 확률변수의 상관정도


- 공분산 = 0 : 상관이 전혀 없는 상태
- 공분산 > 0 : 양의 상관관계
- 공분산 < 0 : 음의 상관관계
- **최소, 최대값이 없어** 강약 판단 불가

2) 상관계수 : 상관정도를 -1 ~ 1값으로 표현

- 상관계수 = 1 : 정비례 관계
- 상관계수 = 0 : 상관없음
- 상관계수 = -1 : 반비례 관계

3) 공분산과 독립성의 관계

- ★두 변수가 독립이면 공분산은 0이지만, 공분산이 0이라고 두 변수가 독립이라고 할 수는 없음



● 기댓값과 분산의 특성

서로 독립인 X, Y 가 각각 정규분포 $N(20, 2^2)$ 와 $N(27, 1^2)$ 을 따른다고 할 때,
확률변수 $Z = 5X - 7Y + 15$ 일 경우의 Z 의 기댓값과 분산의 계산

1) Z 의 기댓값

$$: E(Z) = E(5X - 7Y + 15) = 5 \times 20 - 7 \times 27 + 15 = -74$$

2) Z 의 분산

$$: V(Z) = V(5X - 7Y + 15) = V(5X - 7Y) = 25 \times 2^2 + 49 \times 1^2 = 149$$

※ $V(\text{상수}) = 0$ 으로 취급

기댓값 : 확률변수의 평균


● 첨도와 왜도

(1) 첨도 : 자료의 분포가 얼마나 뾰족한지 나타내는 척도

-첨도 = 3: 정규 분포 형태

→ 3을 빼서 0을 기준으로 정규분포 형태를 판단하기도 함


-값이 클 수록 뾰족한 모양



(2) 왜도 : 자료 분포의 비대칭 정도 (0일 때 대칭)

- 왜도 < 0 : 최빈값 > 중앙값 > 평균값

- 왜도 > 0 : 최빈값 < 중앙값 < 평균값



→ 평균값은 꼬리를 따라감

→ 가장 높은 값이 최빈값

▼ 참고

1. 왜도 > 0 (양의 왜도, 오른쪽 꼬리)

- 분포가 오른쪽으로 긴 꼬리를 가짐
- 평균 > 중앙값 > 최빈값
- 예: 소득 분포 (고소득 소수 때문에 오른쪽 꼬리 김)

2. 왜도 = 0 (대칭 분포)

- 평균 = 중앙값 = 최빈값
- 완벽한 종 모양 (정규분포)

3. 왜도 < 0 (음의 왜도, 왼쪽 꼬리)

- 분포가 왼쪽으로 긴 꼬리를 가짐
- 평균 < 중앙값 < 최빈값
- 예: 시험 점수 (대부분 높고, 일부 극단적 저득점자 있음)

✓ 핵심 정리

- 왜도 > 0 → 오른쪽 꼬리 길다 (Right-skewed)
- 왜도 = 0 → 대칭 (Normal distribution)
- 왜도 < 0 → 왼쪽 꼬리 길다 (Left-skewed)

• Summary 함수 결과의 해석

- 통계 요약 해석			1) Age 변수
	Age	Survived	- Mean, Median 등 존재 → 수치형 변수
Min.	: 0.17	0:266	- 25% 지점 : 21.00, 75% 지점 : 39.00
1st Qu.	:21.00	1:152	- Median < Mean → 왜도 > 0
Median	:27.00		- 결측치(NA's) 개수 : 86개
Mean	:30.27		2) Survived 변수
3rd Qu.	:39.00		- 집단의 빈도 수 → 범주형 변수
Max.	:76.00		- 범주 0과 1이 클래스 불균형 상태
NA's	:86		→ 0을 다운샘플링 하거나 1을 오버샘플링


1) Age 변수 > 평균값, 중앙값 존재

→ 범주형 변수 = 수치X, A에 속하냐 B에 속하냐

평균이 중앙값보다 크다 > 왜도 > 0

Survived 변수 > 0에 속하는지 1에 속하는지 > 범주형 변수

- 시각적 데이터 탐색 (4과목에 있음)



▼ 참고

시각화 종류와 특징

1. Line Plot (선 그래프)

- 시간(time series) 이나 순서가 있는 데이터의 변화 추세를 표현
- 데이터가 연속적일 때 적합

- 예: 주가 변화, 온도 변화

1. Histogram (히스토그램)

- 데이터를 구간(bin)별로 나누어 **분포(빈도)** 를 보여줌
- 데이터의 **분포 형태, 왜도, 첨도** 파악 가능
- 예: 시험 점수 분포, 고객 연령 분포

1. Bar Plot (막대 그래프)

- **범주형 데이터(category)** 의 비교에 사용
- 카테고리별 빈도나 크기를 쉽게 비교 가능
- 예: 지역별 판매량, 제품별 매출

1. Pie Plot (원형 차트)

- 전체에서 각 범주가 차지하는 **비율(%)** 을 보여줌
- 비율 관계는 직관적이지만, 카테고리가 많으면 해석 어려움
- 예: 시장 점유율, 예산 분포

1. Scatter Plot (산점도)

- 두 변수 간의 **관계/상관성**을 시각화
- 선형/비선형 관계, 이상치 탐지 가능
- 예: 키와 몸무게 관계, 광고비와 매출 관계

1. Box Plot (상자 수염 그림)

- 데이터의 **분포 요약 (중앙값, 사분위수, 이상치)** 을 보여줌
- 여러 그룹 비교에도 효과적
- 예: 남/여 시험 점수 분포 비교, 부서별 급여 수준

✓ 요약 비교표

그래프	특징	주로 보는 것
Line Plot	연속적 데이터 추세	시간 변화, 시계열
Histogram	데이터 분포 형태	빈도, 왜도, 첨도
Bar Plot	범주 간 비교	크기 비교
Pie Plot	전체 대비 비율	점유율, 비중
Scatter Plot	변수 간 관계	상관성, 패턴, 이상치
Box Plot	분포 요약	중앙값, 사분위수, 이상치

2. 고급 데이터 탐색

- 시공간 데이터 탐색

- **시공간 데이터**
 - 공간적 정보에 시간의 흐름이 결합된 데이터
 - 활용 : 시공간 **패턴**을 통한 예측, **지도**를 통한 위치정보, 지리공간의 **격자** 차트 결합
→ '**패지컬**'

- 다변량 데이터 탐색

- 다변량 데이터 탐색

- (1) 목표 : 변수 간 관계, 패턴 분석, 이상치 탐지, 데이터 요약
- (2) 방법 : 상관관계분석, PCA, 다차원척도법, 다중선회귀, 군집 분석 등

- 비정형 데이터 탐색

- 자연어 전처리

- (1) 토큰화(Tokenization) : 의미 있는 말뭉치로 문자를 나누는 작업

"I" "like" "apple"

- (2) 불용어(Stop Words) 처리 : 조사, 접속사 등의 의미 없는 정보를 제거

Family ~~is an~~ important thing

- (3) 정규화 : 같은 의미이면서 표현이 다른 단어를 통합

Apple = apple

- (4) 어간추출(stemming) : 접사를 제거하여 기본 형태를 찾아내는 작업

working, works, worked ⇒ work

- (5) 표제어 추출(lemmatization) : 사전에 기반하여 단어를 원형으로 변환

am, are, is ⇒ be

→ 한국어는 띄어쓰기가 일정하지 않고, 형태소 단위로 분리해야 되어 토큰화가 어려움

통계기법 이해

1. 기술통계

- 표본추출

- 전수조사와 표본조사

- 전수조사 : 전체를 다 조사, 시간과 비용이 많이 소모
- 표본조사 : 일부만 추출하여 모집단을 분석



- 확률적 표본 추출 방법

- (1) 랜덤 추출법 : 무작위로 표본 추출
- (2) 계통 추출법(=계층적 추출법) : 번호 부여하여 일정 간격으로 추출
- (3) 집락 추출법(=군집 추출법)
 - 여러 군집으로 나눈 뒤 군집을 선택하여 랜덤 추출
 - 군집 내 이질적 특징, 군집 간 동질적 특징

(4) 층화 추출법

- 군집 내 동질적 특징, 군집 간 이질적 특징
- 같은 비율로 추출 시, **비례 층화 추출법**

(5) 복원, 비복원 추출

- 복원 추출 : 추출되었던 데이터를 **다시 포함**시켜 표본 추출
- 비복원 추출 : 추출되었던 데이터는 제외하고 표본 추출

★ 집락추출법 ↔ 층화 추출법 구분 중요

* 집락

A / B / C 아파트 중

특정 아파트(A)만 방문해서 설문조사 > 집락추출법

A의 검사가 BC를 대변할 것이다 > 군집 간 동질적 특징이 있음

하지만 군집 내에 다양성이 있어야함 > 군집내 이질적 특징

* 층화

1학년 100명

2학년 200명

3학년 300명

→ 같은 학년끼리는 동질적 근데 군집 간 이질적 특성

1:2:3의 비율로 뽑으면 비례층화추출법

60명 뽑는데 실수로 1학년만 60명 뽑음

• 비확률적 표본 추출 방법

- (1) 편의 추출법 : 연구자가 쉽게 접근 가능한 대상으로 표본을 추출
- (2) 의도적 추출법 : 연구자가 특정 기준을 정하고, 이에 맞는 표본을 추출
- (3) 할당 추출법 : 특정 기준으로 나눈 후, 그 그룹에서 할당된 수 만큼 추출
- (4) 눈덩이 추출법 : 초기 응답자로부터 새로운 응답자를 추천 받는 방식
- (5) 자기선택 추출법 : 응답자가 스스로 조사에 참여할지 결정

- 확률분포

• 기초 확률 용어

- (1) 확률 : 통계적 현상의 확실함을 나타내는 척도로 수학적 확률과 통계적 확률로 구분
- (2) 시간 : 여러 반복된 시행을 통해 결과로서 나타나는 표본공간의 부분 집합
- (3) 표본공간 : 통계적 실험에 의하여 일어날 수 있는 모든 가능한 결과
-예) 동전 두 개를 던질 때 표본공간 $S = \{(앞, 앞), (앞, 뒤), (뒤, 앞), (뒤, 뒤)\}$
- (4) 확률변수 : 표본공간의 각 원소에 해당하는 값(확률)을 대응하는 함수
-예) 확률변수 X 가 어떤 집합의 키를 나타낼 때 기가 160~170 확률은 $P(160 \leq X \leq 170)$
- (5) 조건부 확률 : 특정 사건 B가 발생했을 때 A가 발생할 확률
-예) $P(A|B) = P(A \cap B) / P(B)$ (백신을 맞았을 때 감기에 걸릴 확률)
- (6) 독립사건 : A, B가 서로 영향을 주지 않는 사건($P(A|B) = P(A)$)
- $P(A \cap B) = p(A)P(B)$ (주사위 A가 3이 나왔을 때, 주사위 B가 3이 나올 확률)

(7) **배반사건** : A, B가 서로 동시에 일어나지 않는 사건

$P(A \cap B) = \emptyset$ (동전을 던졌을 때 앞면과 뒷면이 동시에 나올 확률)

(8) **베이즈 정리** : 두 확률 변수의 사전 확률과 사후 확률 사이의 관계를 나타내는 정리 (3과목)

$-P(A|B) = P(B|A)P(A)/P(B)$

♥

• 확률분포

-확률 변수의 개별 값들이 가지는 확률 값의 분포

(1) 이산 확률분포

- 값을 셀 수 있는 분포, 확률질량함수로 표현

1) 이산균등분포: 모든 곳에서 값이 일정한 분포

- 예) 주사위의 각 면이 나오는 확률은 모두 동일

2) **베르누이 분포** : 결과가 두 가지 중 한가지로 나타나는 베르누이시행으로 나타나는 분포

- 예) 동전던지기, 시험의 합격/불합격

3) **이항분포** : N번의 베르누이 시행 중 K번 성공할 확률의 분포

- 예) 동전을 20번 던져 앞면이 나오는 횟수

4) **기하분포** : 성공확률이 P인 베르누이시행에서 처음으로 성공할 때까지 시행횟수의 분포

- 예) 동전을 던져 처음으로 앞면이 나오기까지 던진 횟수

5) **음이항분포** : 성공확률이 p인 베르누이 시행을 r번 성공할 때까지 반복 시행횟수의 분포

- 예) 동전을 던져 앞면이 5번 나오기까지 던진 횟수

6) **초기하분포** : N개 중 비복원추출로 n번 추출했을 때 원하는 결과가 k번 나올 확률의 분포

- 예) 10개 구슬 중 4개의 구슬이 당첨 구슬일 때, 4번 뽑았을 때 당첨구슬을 2번 뽑을 확률

7) **다항분포** : N번 시행해서 각 시행이 여러 개의 결과를 가질 수 있는 확률 분포

- 예) 주사위를 20번 던져 각 면이 나오는 횟수

8) **포아송분포** : 단위 시간 내 발생할 수 있는 사건의 발생 횟수에 대한 분포

- 예) 하루동안 발생하는 출생자 수, 한 시간 동안 사무실에 걸려온 전화의 수

→ '베포항항하'

각각의 분포마다 확률질량함수가 있고, 확률질량함수를 토대로 평균, 분산이 있다. > 구글링, 지피티로 찾기

(2) 연속 확률분포

- 값을 셀 수 없는 분포, 확률밀도함수로 표현

1) ★**정규분포** : 우리가 일상생활에서 흔히 보는 확률변수의 평균 분포를 근사한 분포 (Z검정 활용)

- 예) 사람들의 키 혹은 IQ 점수의 분포, 시험 성적의 분포

2) ★**t분포** : 정규분포와 유사하지만, 꼬리 부분이 더 두껍고 긴 분포

- (t검정 활용) 표본이 30개 보다 작은 집단에 대한 평균 검정

3) **카이제곱분포** : 독립적인 정규분포를 따르는 변수들의 제곱합으로 구성된 분포

- (카이제곱 검정 활용) 두 집단의 동질성 검정, 단일 집단의 모분산 검정

4) **F분포** : 두 개의 서로 다른 카이제곱 분포의 비율

- (F검정 활용) 두 집단의 분산 동질성 검정

• 확률분포의 기댓값

- 확률변수 X 의 $f(x)$ 확률분포의 대한 기댓값($E(X)$)

1) 이산적 확률변수 : $E(X) = \sum xf(x)$

2) 연속적 확률변수 : $E(X) = \int xf(x)$

(1) 동전을 3개 던지는 확률실험을 할 때, 확률변수 X (앞면F의 개수)의 기댓값은?
(2) 1~12의 숫자가 표시된 원형시계에서, 확률변수 X (시계 바늘이 가르키는 시간)의 기댓값은?

(1)
- $P(X=0) = P(\{BBB\}) = \frac{1}{8}$
- $P(X=1) = P(\{FBB, BFB, BBF\}) = \frac{3}{8}$
- $P(X=2) = P(\{FFB, FBF, BFF\}) = \frac{3}{8}$
- $P(X=3) = P(\{FFF\}) = \frac{1}{8}$
 $\therefore E(X) = 0 \times \frac{1}{8} + 1 \times \frac{3}{8} + 2 \times \frac{3}{8} + 3 \times \frac{1}{8} = 1.5$

(2)

 $\therefore E(X) = \int_0^{12} xf(x)dx = \int_0^{12} x \left(\frac{1}{12}\right) dx = 6$

가로가 12면 세로는 1/12일 것이다 왜? 면적은 10이 되어야 하니까

$$12 \times 1/12 = 1$$

- 균등분포 $U(a,b)U(a,b)U(a,b)$ 의 평균은 항상 $E[X]=2a+b$

$$E[X]=a+bE[X] = \frac{a+b}{2}$$


- 여기서는 $(0+12)/2=6(0+12)/2 = 6(0+12)/2=6$ 이므로, 적분 결과와 동일하게 평균이 6이 된 거예요.

- 표본분포

- ★★★중심극한정리

- 임의의 모집단으로부터 추출된 표본분포는 표본크기가 충분히 크면(30개 이상) 정규분포
- 모집단의 분포에 상관없이 표본분포가 정규분포를 이룸

→ 정규분포만 알아도 가설검정을 통해 모집단을 예측할 수 있더라



- 표본평균의 표본분포

- (1) 표본평균의 표본분포의 평균 : $E(\bar{X}) = \mu$
 - (2) 표본평균의 표본분포의 분산 : $V(\bar{X}) = \sigma^2/n$
 - (3) 표본평균의 표준오차 : $SE(\bar{X}) = \sigma/\sqrt{n}$
 - (4) 표본평균의 표준화 : $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$
- (μ : 모집단의 평균, σ : 모집단의 표준편차, $\bar{X}$: 표본평균, n : 표본의 크기)

(1) 기댓값 = 무

(2) 분산 = 표준편차의 제곱

(3) 표준오차 : 표본들의 변동성 얼마나 있음? (표본(n)을 많이 뽑을 수록 표준오차 $\rightarrow$ 0에 수렴 / 변동성이 낮아짐)

(4) 표준화 -제트스코어 변환 : 평균빼고 표준편차로 나누면 평균 0 분산 1인 표준정규분포

- 표본비율의 표본분포

- (1) 표본비율 : $\hat{p} = X/n$
- (2) 표본비율의 평균 : $E(\hat{p}) = p$
- (3) 표본비율의 표준오차 : $SE(\hat{p}) = \sqrt{pq/n}$
- (4) 표본비율의 표준화 : $Z = \frac{\hat{p} - p}{\sqrt{pq/n}} \sim N(0,1)$

- 표준비율(정답/오답 두 개밖에 없을 때 n개의 데이터를 뽑았는데 정답의 개수)의 표준 분포

- 표본비율의 표본분포

2. 추론통계

♥

- 점추정

특정값으로 추정 - 배달 20분 뒤 도착

편향 = 오차

- 모집단이 특정한 값으로 추정하며, 추정량(Estimator)으로 모수를 추정

(1) 추정량의 조건

1) 불편성(Unbiasedness) : 추정량의 기댓값이 실제 모수와 같음 (편향(=오차)이 0이 되는 경우)

2) 효율성(Efficiency) : 여러 추정량 중 분산이 작은 것이 더 효율적인 추정량

3) 일치성(Consistency) : 표본 크기가 증가할 수록 추정량이 모수에 가까워짐

4) 충족성(Sufficiency) : 추정량이 모집단의 정보를 최대한 반영

→ '불효일충'

(2) 대표적인 추정량

- 1) 모집단의 평균 $\mu \rightarrow$ 표본평균 $\bar{X} = \frac{1}{n} \sum X$
 - 2) 모집단의 분산 $\sigma^2 \rightarrow$ 표본분산 $s^2 = \frac{1}{n-1} \sum (X - \bar{X})^2$
 - 3) 모집단의 비율 $p \rightarrow$ 표본비율 $\hat{p} = X/n$
- (3) 평균제곱오차(MSE) : 점추정에서 추정량과 실제 모수 간의 평균적인 오차 크기
- $$MSE(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [Bias(\hat{\theta})]^2$$

1) 표본평균 기댓값 = μ

모집단은 n 분의 1로 나누고

표본(분산)은 $n-1$ 로 나눔

>>자유도

(3) 평균제곱오차(MSE) : 점추정에서 추정량과 실제 모수 간의 평균적인 오차 크기

분산 + 편향의 제곱

- 구간추정

10~20분 사이 도착

- 모집단이 특정한 구간으로 추정(95%, 99%를 가장 많이 사용)

- 모평균의 구간추정(신뢰구간) - 1시간 전 후 강의

(1) 모집단의 분산을 알고 있는 경우

$$\bar{X} - Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

- 신뢰수준 95% : $Z_{\frac{\alpha}{2}} = 1.960$

- 신뢰수준 99% : $Z_{\frac{\alpha}{2}} = 2.576$


(2) 모집단의 분산을 모르는 경우

- 자유도가 $n-1$ 인 t 분포를 이용하여 신뢰구간을 추정

$$\bar{X} - t_{\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, n-1} \frac{S}{\sqrt{n}} \quad (S : \text{표본표준편차})$$

(3) 비율에 대한 신뢰 구간

$$\hat{p} - Z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + Z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$



→ 신뢰수준 95%면 그래프 넓이가 0.95

일반적으로 가장 많이 사용

양끝은 각각 0.025(0.5/2)

→ 신뢰수준 99%면 그래프 넓이가 0.99

- 가설검정

- 모집단의 특성에 대한 주장을 가설로 세우고 표본조사로 가설의 채택여부를 판정

- 귀무가설 (H_0) : 일반적으로 생각하는 가설 (차이가 없다)
- 대립가설 (H_1) : 귀무가설을 기각하는 가설, **증명하고자 하는 가설** (차이가 있다, 크다/작다)
- 검정통계량 : 귀무가설을 기각할지 결정하기 위해 표본으로 산출되는 통계량
- 유의수준 (α) : 귀무가설이 참일 때 기각하는 **1종 오류**를 범할 확률의 허용 한계 (일반적 0.05)
- 기각역 : 귀무가설이 기각되고 대립가설이 채택되는 **검정통계량**의 영역

#귀무가설이 사실인데 거짓이라고 판정 = 1종오류(판매자 오류)

#귀무가설이 거짓인데 사실이라고 판정 = 2종오류(소비자 오류)

1인분 200g인 식당에서, 1인분이 200g이 아닌 거 같을 때

H_0 : 1인분 $\rightarrow$ 200g


H_1 : 1인분 200g아니다

검정결과 실제	H_0 가 사실이라고 판정	H_0 가 거짓이라고 판정
H_0 가 사실	옳은 결정	1종 오류(α)
H_0 가 거짓	2종 오류(β)	옳은 결정

유의수준 일반적으로 5%

- 가설 검정 문제 풀이 방법

- 귀무가설 / 대립가설 설정
 - '차이가 없다' 혹은 '동일하다' $\rightarrow$ 귀무가설
- 양측 혹은 단측검정 확인
 - 대립가설의 값이 '같지 않다' $\rightarrow$ 양측검정 (**작다, 크다 다 검정**)
 - '값이 크다', '값이 작다' $\rightarrow$ 단측검정
- 일표본 혹은 이표본 확인
 - 하나의 모집단 $\rightarrow$ 일표본
 - 두 개의 모집단 $\rightarrow$ 이표본
- 검정통계량 계산과 기각역 판단
 - 검정통계량이 기각역에 존재 $\rightarrow$ 귀무가설 기각
 - 검정통계량이 채택역에 존재 $\rightarrow$ 귀무가설 채택
- t검정인 경우 - 단일표본, 대응표본, 독립표본 확인
 - 모집단에 대한 평균검정 $\rightarrow$ 단일표본
 - 동일 모집단에 대한 평균비교 검정 $\rightarrow$ 대응표본
 - 서로 다른 모집단에 대한 평균비교 검정 $\rightarrow$ 독립표본



A 공장에서의 제품의 불량률은 1.7%, 모표준편차 0.3%로 관리하고 있다. 이 공장에서 9개의 샘플을 활용하여 분석하였더니 불량률이 평균 1.5%였다. 이 공장의 불량률을 1.7%로 관리하고 있다는 주장에 대해서 의문을 제기할 때, 5% 유의수준으로 가설검정을 수행 ($Z_{0.05} = 1.645, Z_{0.025} = 1.96$)

1) 귀무가설/대립가설 설정

- '차이가 없다' 혹은 '동일하다' → 귀무가설로 설정

: A공장의 불량률은 1.7%이다.

2) 양측 혹은 단측검정 확인

- 대립가설의 값이 같지 않다 → 양측검정

3) 일표본 혹은 이표본 확인

- 한개의 모집단 → 일표본

4) 검정통계량 계산과 기각역 판단

- 검정통계량 : $Z_o = (\bar{X} - \mu) / (\sigma / \sqrt{n}) = (1.5 - 1.7) / (0.3 / \sqrt{9}) = -2.0$
- 기각역 : $\pm Z_{0.025} = \pm 1.96$
- 판정 : $Z_o < -1.96 \rightarrow$ 귀무가설 기각

(심화) 모표준편차를 모르는 경우 (표본표준편차가 0.3% 일 때) → t검정을 사용

1), 2), 3)은 동일

4) 검정통계량 계산과 기각역 판단

- 검정통계량 : $t_o = (\bar{X} - \mu) / (S / \sqrt{n}) = (1.5 - 1.7) / (0.3 / \sqrt{9}) = -2.0$
- 기각역 : $\pm t_{0.025, 8} = \pm 2.18$
- 판정 : $t_o > -2.18 \rightarrow$ 귀무가설 채택

5) 단일표본, 대응표본, 독립표본 확인


- 모집단에 대한 평균검정 → 단일표본

양측검정일 때 0.025


단측일 때 $\alpha/2$ 사용

대립가설

A공장의 불량률은 1.7%가 아니다.



이번에는 A공장의 불량품이 1.7보다 “작다”



귀무가설이 같다, 다르다 / 크다, 작다는 쓰는 법이 다름

z검정으로 검정 > 기각

t검정 > 모표준 편차를 몰라서 더 러프해짐 > 채택